

WHITE BLOOD CELL CLASSIFIER — DARBA APRAKSTS

Tika izstrādāta pilnvērtīga MLOps sistēma balto asinsķermenīšu attēlu klasifikācijai četrās klasēs (eozinofili, limfocīti, monocīti, neitrofili). Sistēma ietver modeļa apmācību ar Keras (MobileNetV2 transfer learning), eksperimenta vadību ar MLflow, automātisku labākā modeļa izvēli un iegaumēšanu, Streamlit lietotni prognozēm, un visas sistēmas konteinerizāciju ar Docker Compose, kur Streamlit lietotne un MLflow serveris darbojas kā divi savstarpēji savienoti servisi.

Galvenā doma ir tāda, ka modelis ne tikai tiek izveidots, bet arī integrēts lietojamā un reproducējamā sistēmā. Lietotne ielādē modeli no MLflow Model Registry (modeli, kas atzīmēti ar "champion" aliasu), nevis no hard-coded faila.

Novērojumi

- Tika izvēlēta Blood Cell Images datu kopa ar gatavu klašu mapju struktūru, kas atbilst klasifikācijas uzdevumam un dod loģiskas accuracy/precision/recall/F1 metrikas;
- Iesaldēts MobileNetV2 sākumā sasniedza tikai 53% precizitāti, jo asins šūnu attēli atšķīrās no ImageNet attēliem, uz kuriem tas apmācīts. Lai problēmu risinātu tika pievienots divpakāpju fine-tuning — vispirms apmācīta jaunā klasifikācijas galva (head), tad atsaldēti MobileNetV2 augšējie slāņi ar ļoti zemu mācīšanās ātrumu;
- Validācijas precizitāte izskatījās daudzsološa (~71%), bet testa precizitāte joprojām bija zema (~53%). Padziļināta analīze atklāja, ka datu kopa sastāv no augmentētiem attēliem, kas atvasināti no neliela oriģinālu skaita, un autora sagatavotais TRAIN/TEST sadalījums radīja nevienmērīgu informācijas noplūdi. Risinājums — apvienot visus attēlus un sadalīt no jauna 70/15/15. Šāda pieeja būtiski uzlaboja kvalitāti no ~53% uz ~96%;
- Agresīvāks fine-tuning (vairāk atsaldētu slāņu, augstāks mācīšanās ātrums) noveda pie pārmācīšanās — treniņa precizitāte auga, bet validācija stagnēja un zudums auga. Risinājums bija — zemāks mācīšanās ātrums, datu augmentācija, ReduceLROnPlateau un EarlyStopping;
- Eksperiments ar 40 atsaldētiem slāņiem (nevis 30) praksē sevi parādīja neapmierinoši (validācijas zudums uzlēca līdz 2.7–3.2 vienībām). Tas apstiprina, ka vairāk atsaldētu slāņu nav labāk — ar nelielu datu kopu modelis "aizmirst" noderīgās ImageNet zināšanas ātrāk, nekā paspēj iemācīties jaunas;
- Modeļa ceļš sākotnēji bija cieti iekodēts lietotnē. Tas tika padarīts konfigurējams ar vides mainīgajiem (MODEL_DIR, MLFLOW_TRACKING_URI), lai viens un tas pats kods strādātu gan lokāli, gan Docker konteinerā;
- Docker konteinerā lietotne sākumā nebija pieejama no pārlūka. Kā risinājums tika uzstādīta Streamlit `address = 0.0.0.0` failā `.streamlit/config.toml`, lai serviss pieejams no visām adresēm, ne tikai no konteinerā.

Būtiskākais

Lielākā mācība bija datu kvalitātes un datu sadalījuma nozīme. Sākotnējie sliktie rezultāti (~53%) nebija modeļa vai koda kļūda — tie bija pareizs, godīgs novērtējums uz nepareizi

sadalītiem augmentētiem datiem. Tikai saprotot, kā datu kopa tika izveidota (augmentācija no neliela oriģinālu skaita), kļuva skaidrs, kāpēc validācija un tests atšķiras un kā to atrisināt.

Visa eksperimentu vēsture — ieskaitot agrīnos zema rezultāta mēģinājumus — ir saglabāta MLflow, kas parāda ne tikai gala rezultātu, bet arī ceļu līdz tam un pieņemtos lēmumus rezultāta sasniegšanā.